Agrupamento de Gostos Musicais e de Jogos com K-Means e Agrupamento Hierárquico Aglomerativo

Henrique Ribeiro Rodrigues[1]

[1]Universidade Federal da Fronteira Sul (UFFS) – Chapecó, SC – Brasil
Inteligência Artificial (GEX1225) – Prof. Felipe Grando

henrique.ribeiro@uffs.edu.br

Abstract. *This report applies two clustering algorithms from the scikit-learn library, K-Means and agglomerative hierarchical clustering, to a dataset describing the preferences of 152 people for 21 music genres and 21 game genres. Several parameter settings were tested and evaluated with internal metrics. Both algorithms were run with three clusters and produced similar partitions (87.5% agreement), revealing three profiles: eclectic heavy gamers; rock, indie and metal listeners with few interests; and sertanejo, reggaeton and funk listeners who prefer casual games. Based on the centroids, Survival or RPG games are recommended for people who like Brega music, and Rock music for people who do not like board games.*

Resumo. *Este relatório aplica dois algoritmos de agrupamento da biblioteca scikit-learn, o K-Means e o agrupamento hierárquico aglomerativo, a um conjunto de dados com os gostos de 152 pessoas por 21 estilos musicais e 21 estilos de jogos. Diversas configurações de parâmetros foram testadas e avaliadas com métricas internas. Os dois algoritmos foram executados com três grupos e produziram partições semelhantes (87,5% de concordância), revelando três perfis: ecléticos que jogam muito; ouvintes de rock, indie e metal com poucos interesses; e ouvintes de sertanejo, reggaeton e funk que preferem jogos casuais. A partir dos centroides, recomenda-se Survival ou RPG para quem gosta de Brega e Rock para quem não gosta de jogos de tabuleiro.*

1. Introdução

O agrupamento (*clustering*) é uma tarefa de aprendizagem não supervisionada que divide amostras sem rótulo em grupos, de modo que amostras do mesmo grupo sejam parecidas entre si e diferentes das amostras dos outros grupos. Neste trabalho, essa técnica é aplicada a um conjunto de dados sobre gostos musicais e de jogos, disponibilizado no SIGAA, com o objetivo de identificar perfis de pessoas e usá-los para fazer recomendações.

Foram utilizados dois algoritmos da biblioteca scikit-learn (Pedregosa *et al.*, 2011): o K-Means, exigido pela atividade, e o agrupamento hierárquico aglomerativo (AgglomerativeClustering), escolhido por seguir uma estratégia bem diferente, o que torna a comparação mais informativa. Para cada algoritmo foram testadas diversas configurações de parâmetros; a configuração escolhida foi executada e o grupo de cada amostra e os centroides de cada grupo foram armazenados.

A Seção 2 descreve os dados e as métricas de avaliação; a Seção 3 apresenta os algoritmos, os experimentos e as configurações escolhidas; a Seção 4 analisa os resultados, identifica o grupo do autor e responde às perguntas de recomendação; a Seção 5 conclui o trabalho.

2. Dados e Metodologia

2.1 Conjunto de Dados

O arquivo MusicasJogosDataset_20232_20262.csv contém 152 amostras (pessoas) e 42 atributos binários: 21 estilos musicais (de Pop a Clássica) e 21 estilos de jogos (de FPS a Realidade Virtual). O valor 1 indica que a pessoa gosta do estilo e 0 que não gosta. O nome da pessoa foi usado apenas como identificador. Não há valores ausentes, e nenhum dado externo foi usado para completar o conjunto.

Como todos os atributos estão na mesma escala, não foi aplicada normalização. Nesse caso, o centroide de um grupo indica a proporção de pessoas do grupo que gostam de cada estilo. Os estilos mais populares são Rock (0,88) e Pop (0,83); os menos populares são Brega (0,18) e K-Pop (0,22). Em média, cada pessoa gosta de 21,2 dos 42 estilos.

2.2 Métricas de Avaliação

Como não existem rótulos verdadeiros, as configurações foram comparadas com métricas internas, além da interpretação dos centroides:

Silhueta: varia de −1 a 1; valores maiores indicam grupos mais coesos e separados (Rousseeuw, 1987). Foi calculada com a distância euclidiana e com a distância de Jaccard, que ignora as coausências (dois "não gosto") e é adequada a dados binários.

Davies-Bouldin e Calinski-Harabasz: o primeiro é melhor quanto menor; o segundo, quanto maior.

Inércia: soma dos quadrados das distâncias ao centroide, usada no método do cotovelo do K-Means.

Índice de Rand ajustado (ARI): mede a concordância entre duas partições (1 = idênticas; perto de 0 = casual). Foi usado para medir a estabilidade do K-Means entre sementes e para comparar os algoritmos.

Tamanho do menor e do maior grupo: usado para detectar partições degeneradas, como um grupo com uma única pessoa.

3. Algoritmos e Configurações

3.1 Algoritmos Escolhidos

O **K-Means** (MacQueen, 1967) divide as amostras em *k* grupos representados por centroides. A cada iteração, atribui cada amostra ao centroide mais próximo e recalcula os centroides como a média das amostras do grupo, minimizando a inércia. O resultado depende dos centroides iniciais; por isso, usa-se a inicialização k-means++ (Arthur; Vassilvitskii, 2007) e várias reinicializações (n_init), mantendo a de menor inércia.

O **agrupamento hierárquico aglomerativo** começa com cada amostra em um grupo próprio e, a cada passo, funde os dois grupos mais próximos, formando uma hierarquia (dendrograma) que é cortada no número de grupos desejado. A proximidade entre grupos é definida pela ligação: *single* (pontos mais próximos), *complete* (pontos mais distantes), *average* (média das distâncias) ou *ward* (menor aumento da variância intragrupo; Ward, 1963). A Tabela 1 resume as principais diferenças teóricas entre os dois algoritmos.

Tabela 1 – Principais diferenças teóricas entre os algoritmos

Aspecto	K-Means	Aglomerativo (ligação de Ward)
Estratégia	Particional e iterativo: refina uma partição inicial.	Hierárquico ascendente: parte de grupos unitários e funde pares.
Número de grupos	Fixado antes da execução (k).	Definido pelo corte do dendrograma (n_clusters ou distance_threshold).
Critério	Minimiza a inércia global (soma dos quadrados das distâncias ao centroide).	A cada passo, funde o par que menos aumenta a variância intragrupo (decisão local).
Revisão	Amostras podem trocar de grupo a cada iteração.	Fusões são definitivas e não são revistas.
Determinismo	Depende da inicialização; pode parar em mínimos locais (mitigado por n_init).	Determinístico para os mesmos dados.
Centroides	Gerados pelo algoritmo (cluster_centers_).	Não gerados; precisam ser calculados à parte.
Custo	Aproximadamente linear no número de amostras.	Pelo menos quadrático (matriz de distâncias).

Fonte: elaborada pelo autor (2026).

3.2 Variações do K-Means

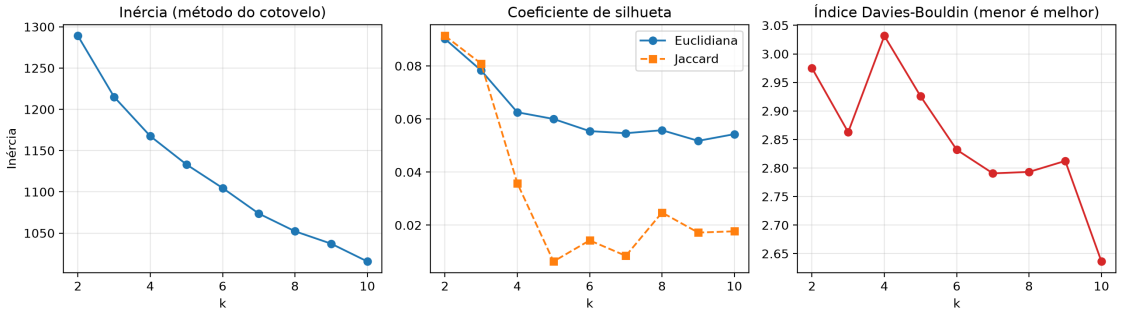
O K-Means foi executado com k de 2 a 10 e com as inicializações k-means++ e random, sempre com n_init = 50 e random_state = 42. Para medir a sensibilidade à inicialização, cada k também foi executado dez vezes com n_init = 1 e sementes diferentes, calculando-se o ARI médio entre essas execuções. A Tabela 2 e a Figura 1 mostram os resultados com k-means++.

Tabela 2 – Variações do K-Means (init = k-means++, n_init = 50)

k	Inércia	Silhueta (euclid.)	Silhueta (Jaccard)	Davies-Bouldin	Calinski-Harabasz	ARI entre sementes	Grupos (mín.–máx.)
2	1289,0	0,090	0,091	2,975	16,84	0,619	75–77
3	1215,1	0,078	0,081	2,863	13,40	0,476	36–61
4	1167,6	0,062	0,036	3,032	11,25	0,366	33–44
5	1133,2	0,060	0,006	2,926	9,75	0,335	22–37
6	1104,6	0,055	0,014	2,832	8,70	0,310	18–31
7	1073,6	0,055	0,008	2,791	8,11	0,287	12–28
8	1052,2	0,056	0,025	2,793	7,46	0,269	14–24
9	1037,2	0,052	0,017	2,812	6,83	0,264	10–22
10	1015,6	0,054	0,018	2,636	6,50	0,261	9–28

Fonte: elaborada pelo autor (2026).

Figura 1 – Inércia, silhueta e índice de Davies-Bouldin do K-Means em função de k



Fonte: elaborada pelo autor (2026).

A inércia não apresenta um cotovelo nítido, mas a redução diminui a partir de k = 3 (queda de 73,9 de k = 2 para 3 e de 47,6 de 3 para 4). A silhueta é máxima em k = 2 (0,090), mas k = 3 fica muito próximo (0,078) e tem o melhor Davies-Bouldin entre k = 2 e k = 5 (2,863). A partir de k = 4, a silhueta com Jaccard despenca (0,036), indicando que os grupos adicionais deixam de ser distintos. A inicialização random gerou valores praticamente iguais, mas foi menos estável em k = 3 (ARI de 0,378 contra 0,476).

3.3 Variações do Agrupamento Aglomerativo

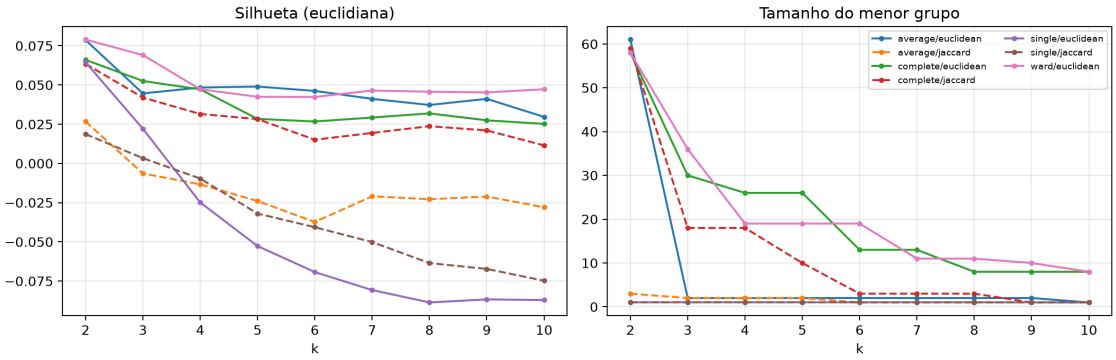
O aglomerativo foi testado com k de 2 a 10 e com as ligações ward (euclidiana), complete, average e single, estas três combinadas com as métricas euclidiana, manhattan, cosseno e Jaccard (esta última por meio de uma matriz de distâncias pré-calculada). A Tabela 3 mostra os resultados para k = 3 e a Figura 2 compara as combinações para todos os valores de k.

Tabela 3 – Variações do agrupamento aglomerativo (ligação × métrica) com k = 3

Ligação	Métrica	Silhueta (euclid.)	Silhueta (Jaccard)	Davies-Bouldin	Calinski-Harabasz	Grupos (mín.–máx.)
ward	euclidiana	0,069	0,069	3,109	12,18	36–58
complete	euclidiana	0,052	0,064	3,396	10,50	30–64
complete	manhattan	0,052	0,064	3,396	10,50	30–64
complete	cosseno	0,019	0,039	4,537	5,36	19–88
complete	Jaccard	0,042	0,086	3,186	8,24	18–93
average	euclidiana	0,045	-0,001	2,569	8,31	2–91
average	manhattan	0,055	0,014	2,320	8,24	1–89
average	cosseno	-0,007	0,219	1,438	1,90	2–148
average	Jaccard	-0,006	0,213	1,550	2,21	2–147
single	euclidiana	0,022	0,072	0,896	1,24	1–150
single	manhattan	0,022	0,072	0,896	1,24	1–150
single	cosseno	0,003	0,242	0,922	1,15	1–150
single	Jaccard	0,003	0,242	0,922	1,15	1–150

Fonte: elaborada pelo autor (2026).

Figura 2 – Silhueta e tamanho do menor grupo do aglomerativo em função de k

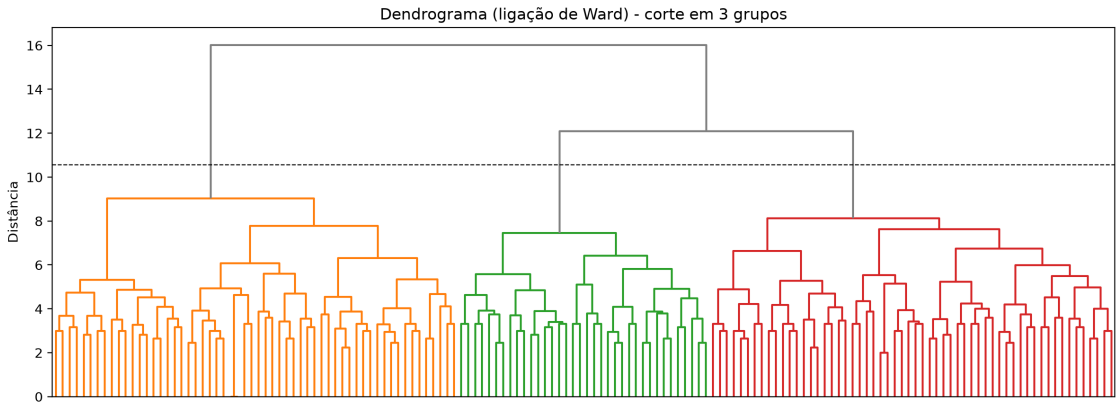


Fonte: elaborada pelo autor (2026).

As ligações single e average geraram partições degeneradas: com single e k = 2, um grupo tem 1 pessoa e o outro 151 (efeito de encadeamento); com average e cosseno, 2 contra 150. Ainda assim, essas partições obtiveram as maiores silhuetas com Jaccard (até 0,266), mostrando que a silhueta isolada pode premiar soluções inúteis. A ligação complete com Jaccard também ficou desbalanceada em k = 3 (18 contra 93). Somente Ward produziu grupos equilibrados (36 a 58 pessoas em k = 3), com os melhores valores de Calinski-Harabasz.

Com Ward, k = 2 tem silhueta um pouco maior (0,079) que k = 3 (0,069), mas k = 3 tem a maior silhueta com Jaccard entre todos os k (0,069); em k = 4 ela cai para -0,001. O dendrograma (Figura 3) mostra uma separação clara em três ramos.

Figura 3 – Dendrograma com ligação de Ward e corte em três grupos



Fonte: elaborada pelo autor (2026).

3.4 Configurações Escolhidas

Escolheu-se **k = 3 para os dois algoritmos**. Esse valor equilibra as métricas internas e gera grupos mais informativos que k = 2: com dois grupos, a divisão reflete principalmente a quantidade de estilos de que cada pessoa gosta, enquanto com três surge um perfil de gosto bem definido. Usar o mesmo k também permite comparar os algoritmos diretamente. A Tabela 4 apresenta as configurações.

Tabela 4 – Configurações escolhidas

Algoritmo	Parâmetros	Centroides
KMeans	n_clusters = 3; init = k-means++; n_init = 50; random_state = 42; demais no padrão (max_iter = 300, tol = 1e-4)	cluster_centers_
AgglomerativeClustering	n_clusters = 3; linkage = ward; metric = euclidean (exigida pelo Ward); demais no padrão	NearestCentroid (média de cada grupo)

Fonte: elaborada pelo autor (2026).

O valor n_init = 50 foi adotado porque, com uma única inicialização, a concordância entre execuções em k = 3 é baixa (ARI de 0,476). Como a classe AgglomerativeClustering não gera centroides, eles foram calculados com NearestCentroid, que obtém a média das amostras de cada grupo. Os grupos foram renumerados em ordem decrescente de tamanho, e o grupo de cada amostra e os centroides foram armazenados nos arquivos grupos_por_amostra.csv, centroides_kmeans.csv e centroides_aglomerativo.csv.

4. Resultados

4.1 Grupos Gerados

Os dois algoritmos geraram três grupos. A Tabela 5 mostra quantas amostras caíram em cada um.

Tabela 5 – Quantidade de amostras por grupo

Grupo	K-Means	Aglomerativo
Grupo 0	61 (40,1%)	58 (38,2%)
Grupo 1	55 (36,2%)	58 (38,2%)
Grupo 2	36 (23,7%)	36 (23,7%)
Total	152 (100,0%)	152 (100,0%)

Fonte: elaborada pelo autor (2026).

O grupo 2 tem 36 pessoas nos dois algoritmos, e a diferença está na fronteira entre os grupos 0 e 1 (61/55 no K-Means e 58/58 no aglomerativo). A Tabela 6 cruza as duas partições: 133 das 152 pessoas (87,5%) ficaram no grupo correspondente nos dois algoritmos, e o ARI entre elas é 0,657, uma concordância alta, mas não total.

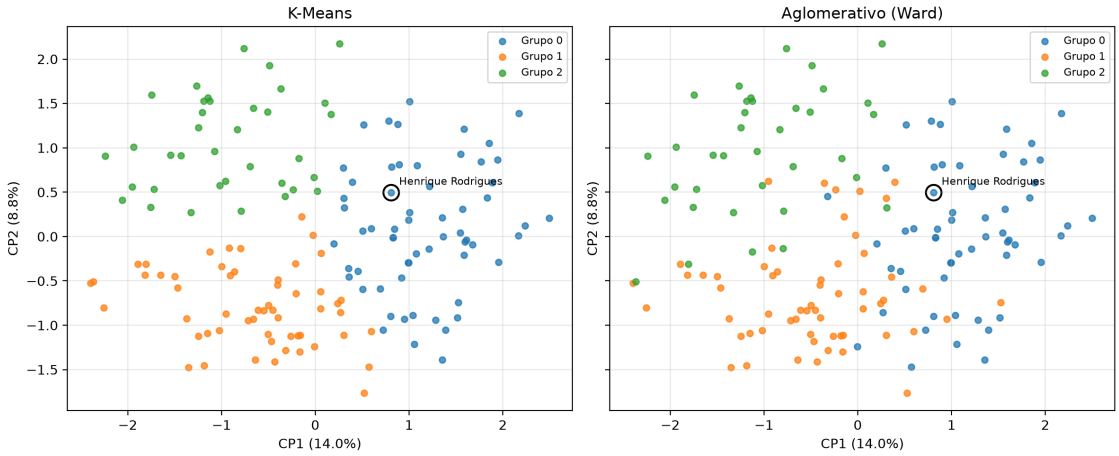
Tabela 6 – Contingência entre os grupos do K-Means (linhas) e do aglomerativo (colunas)

	Aglo. 0	Aglo. 1	Aglo. 2	Total
K-Means 0	54	6	1	61
K-Means 1	3	48	4	55
K-Means 2	1	4	31	36
Total	58	58	36	152

Fonte: elaborada pelo autor (2026).

A Figura 4 projeta as amostras nos dois primeiros componentes principais (PCA), apenas para visualização. Eles explicam 14,0% e 8,8% da variância, e os grupos aparecem como regiões contíguas, sem lacunas entre si.

Figura 4 – Projeção das amostras nos dois primeiros componentes principais

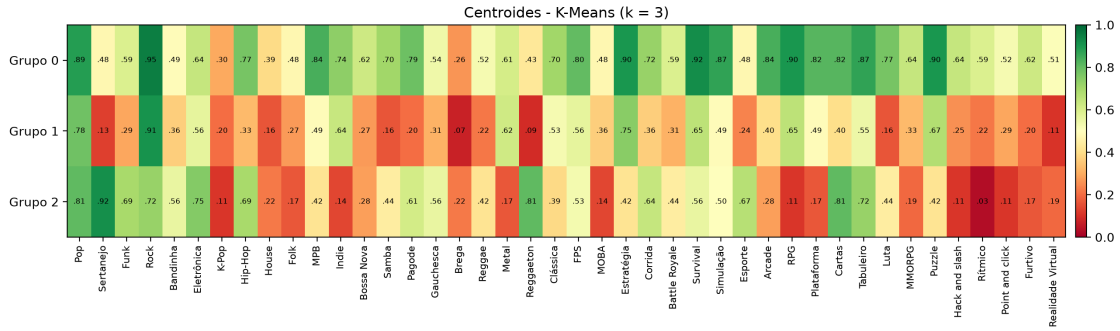


Fonte: elaborada pelo autor (2026).

4.2 Caracterização dos Grupos

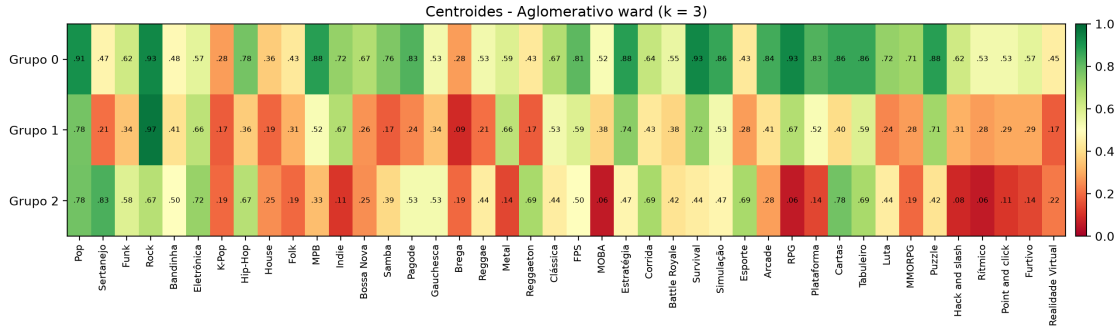
As Figuras 5 e 6 mostram os centroides (verde = a maioria do grupo gosta; vermelho = a maioria não gosta), e a Tabela 7 traz os valores completos. As características predominantes foram identificadas pelos valores extremos de cada centroide, comparados com a média geral.

Figura 5 – Centroides dos grupos do K-Means



Fonte: elaborada pelo autor (2026).

Figura 6 – Centroides dos grupos do agrupamento aglomerativo



Fonte: elaborada pelo autor (2026).

Grupo 0 – ecléticos que jogam muito (K-Means: 61; aglomerativo: 58). Gostam de mais estilos (média de 27,9 dos 42). Valores muito altos em Rock (0,95), Survival (0,92), RPG (0,90), Estratégia (0,90), Puzzle (0,90) e Tabuleiro (0,87), e os maiores valores acima da média em Luta, Arcade, Plataforma e Rítmico. No aglomerativo, também se destaca em Samba (0,76) e Pagode (0,83). Os valores mais baixos são Brega (0,26) e K-Pop (0,30).

Grupo 1 – ouvintes de rock, indie e metal com poucos interesses (K-Means: 55; aglomerativo: 58). Gostam de menos estilos (média de 16,1). Valores altos em Rock (0,91; 0,97 no aglomerativo), Pop (0,78) e Estratégia (0,75) e, apesar de gostarem de poucos estilos, ficam acima da média em Metal (0,62) e Indie (0,64). Valores muito baixos em Brega (0,07), Reggaeton (0,09), Realidade Virtual (0,11), Sertanejo (0,13), Samba (0,16) e Luta (0,16).

Grupo 2 – ouvintes de música popular brasileira e latina que preferem jogos casuais (K-Means: 36; aglomerativo: 36). Valores muito altos em Sertanejo (0,92), Reggaeton (0,81), Funk (0,69) e Eletrônica (0,75), e nos jogos Cartas (0,81), Tabuleiro (0,72), Esporte (0,67) e Corrida (0,64). Valores muito baixos em RPG (0,11), Rítmico (0,03), Hack and slash (0,11), MOBA (0,14), Indie (0,14) e Metal (0,17). É o grupo mais distinto e o mais parecido entre os dois algoritmos.

Tabela 7 – Centroides dos grupos (proporção de pessoas do grupo que gostam de cada estilo)

Estilo	KM 0	KM 1	KM 2	AG 0	AG 1	AG 2	Média
Pop (M)	0,89	0,78	0,81	0,91	0,78	0,78	0,83
Sertanejo (M)	0,48	0,13	0,92	0,47	0,21	0,83	0,45
Funk (M)	0,59	0,29	0,69	0,62	0,34	0,58	0,51
Rock (M)	0,95	0,91	0,72	0,93	0,97	0,67	0,88
Bandinha (M)	0,49	0,36	0,56	0,48	0,41	0,50	0,46
Eletrônica (M)	0,64	0,56	0,75	0,57	0,66	0,72	0,64
K-Pop (M)	0,30	0,20	0,11	0,28	0,17	0,19	0,22
Hip-Hop (M)	0,77	0,33	0,69	0,78	0,36	0,67	0,59
House (M)	0,39	0,16	0,22	0,36	0,19	0,25	0,27
Folk (M)	0,48	0,27	0,17	0,43	0,31	0,19	0,33
MPB (M)	0,84	0,49	0,42	0,88	0,52	0,33	0,61
Indie (M)	0,74	0,64	0,14	0,72	0,67	0,11	0,56
Bossa Nova (M)	0,62	0,27	0,28	0,67	0,26	0,25	0,41
Samba (M)	0,70	0,16	0,44	0,76	0,17	0,39	0,45
Pagode (M)	0,79	0,20	0,61	0,83	0,24	0,53	0,53
Gauchesca (M)	0,54	0,31	0,56	0,53	0,34	0,53	0,46
Brega (M)	0,26	0,07	0,22	0,28	0,09	0,19	0,18
Reggae (M)	0,52	0,22	0,42	0,53	0,21	0,44	0,39
Metal (M)	0,61	0,62	0,17	0,59	0,66	0,14	0,51
Reggaeton (M)	0,43	0,09	0,81	0,43	0,17	0,69	0,39
Clássica (M)	0,70	0,53	0,39	0,67	0,53	0,44	0,57
FPS (J)	0,80	0,56	0,53	0,81	0,59	0,50	0,65
MOBA (J)	0,48	0,36	0,14	0,52	0,38	0,06	0,36
Estratégia (J)	0,90	0,75	0,42	0,88	0,74	0,47	0,73
Corrida (J)	0,72	0,36	0,64	0,64	0,43	0,69	0,57
Battle Royale (J)	0,59	0,31	0,44	0,55	0,38	0,42	0,45
Survival (J)	0,92	0,65	0,56	0,93	0,72	0,44	0,74
Simulação (J)	0,87	0,49	0,50	0,86	0,53	0,47	0,64
Esporte (J)	0,48	0,24	0,67	0,43	0,28	0,69	0,43
Arcade (J)	0,84	0,40	0,28	0,84	0,41	0,28	0,55
RPG (J)	0,90	0,65	0,11	0,93	0,67	0,06	0,62
Plataforma (J)	0,82	0,49	0,17	0,83	0,52	0,14	0,55
Cartas (J)	0,82	0,40	0,81	0,86	0,40	0,78	0,66
Tabuleiro (J)	0,87	0,55	0,72	0,86	0,59	0,69	0,72
Luta (J)	0,77	0,16	0,44	0,72	0,24	0,44	0,47
MMORPG (J)	0,64	0,33	0,19	0,71	0,28	0,19	0,42
Puzzle (J)	0,90	0,67	0,42	0,88	0,71	0,42	0,70
Hack and slash (J)	0,64	0,25	0,11	0,62	0,31	0,08	0,38
Rítmico (J)	0,59	0,22	0,03	0,53	0,28	0,06	0,32
Point and click (J)	0,52	0,29	0,11	0,53	0,29	0,11	0,34
Furtivo (J)	0,62	0,20	0,17	0,57	0,29	0,14	0,36
Realidade Virtual (J)	0,51	0,11	0,19	0,45	0,17	0,22	0,29

Fonte: elaborada pelo autor (2026).

4.3 Diferenças e Observações

Estrutura de grupos fraca: todas as silhuetas ficaram abaixo de 0,10. Os gostos formam um contínuo, e não grupos naturalmente separados; os grupos são úteis como perfis, mas pessoas próximas da fronteira podem mudar de grupo com pequenas alterações.

Quantidade de gostos como eixo principal: o primeiro componente principal tem correlação de 0,95 com o número de estilos de que a pessoa gosta. Assim, a separação entre os grupos 0 e 1 se deve em boa parte a "gostar de muitas coisas" contra "gostar de poucas"; já o grupo 2 é definido pelo tipo de gosto.

Diferença entre os algoritmos: as 19 discordâncias ocorrem sobretudo entre os grupos 0 e 1. O K-Means, que reatribui amostras a cada iteração, coloca mais pessoas no grupo 0; o aglomerativo, cujas fusões não são revistas, desloca algumas para o grupo 1, e seu grupo 0 fica mais marcado por Samba, Pagode, MPB e MMORPG.

Sensibilidade à inicialização: com n_init = 1, o K-Means chega a partições bem diferentes conforme a semente (ARI médio de 0,476 em k = 3). O aglomerativo, por ser determinístico, não tem esse problema.

Métricas equivalentes: para dados binários, as distâncias euclidiana e manhattan produziram exatamente as mesmas partições, pois a euclidiana é a raiz quadrada da manhattan e a ordem entre as distâncias é preservada.

4.4 Grupo do Integrante

O autor consta no conjunto de dados como "Henrique Rodrigues" e foi alocado no **grupo 0 pelo K-Means** e no **grupo 0 pelo aglomerativo**, isto é, no perfil de ecléticos que jogam muito. Ele gosta de 26 dos 42 estilos, perto da média do grupo (27,9).

As características predominantes do grupo se confirmam no seu perfil: gosta de Rock, Survival, RPG, Estratégia, Puzzle, Simulação e Tabuleiro, que estão entre os maiores valores do centroide, e de Luta, um dos atributos mais acima da média. No aglomerativo, o grupo também se destaca em Samba, Pagode, MPB e MMORPG, de que o autor também gosta. Ele não gosta de Brega, K-Pop e House, os valores mais baixos do centroide. A principal divergência é Pop, de que o autor não gosta, apesar de o centroide indicar 0,89. A silhueta individual é positiva nos dois algoritmos (0,082 e 0,077), o que indica uma alocação coerente.

4.5 Recomendação para Quem Gosta de Brega

Brega é o estilo menos popular (28 das 152 pessoas). Para a recomendação, identificou-se o grupo cujo centroide tem o maior valor de Brega e, nele, o estilo de jogo de maior valor.

K-Means: o grupo 0 tem o maior valor de Brega (0,26, contra 0,07 e 0,22) e reúne 16 das 28 pessoas que gostam de Brega. O jogo de maior valor é **Survival** (0,92), seguido de RPG, Estratégia e Puzzle (0,90).

Aglomerativo: também é o grupo 0 (Brega = 0,28; 16 das 28 pessoas). Survival e RPG empatam como maior valor (0,93), mas RPG é o jogo mais acima da média no grupo; por isso, recomenda-se **RPG**.

O grupo 2 também tem valor relativamente alto de Brega (0,22) e prefere Cartas e Tabuleiro. Consultando os dados diretamente, sem agrupamento, os jogos mais comuns entre as 28 pessoas que gostam de Brega são Simulação e Tabuleiro (82% cada). A diferença mostra que a recomendação por grupos reflete o perfil geral do grupo, já que quem gosta de Brega é minoria em todos eles.

4.6 Recomendação para Quem Não Gosta de Tabuleiro

Neste caso, procurou-se o grupo cujo centroide tem o menor valor de Tabuleiro e, nele, o estilo musical de maior valor.

K-Means: o grupo 1 tem o menor valor de Tabuleiro (0,55, contra 0,87 e 0,72) e reúne 25 das 43 pessoas que não gostam de Tabuleiro. O estilo de maior valor é **Rock** (0,91); os mais característicos do grupo são Metal (0,62) e Indie (0,64).

Aglomerativo: também é o grupo 1 (Tabuleiro = 0,59; 24 das 43 pessoas), com Rock ainda mais alto (0,97). Recomenda-se **Rock**, com Metal e Indie como alternativas.

Aqui os dois algoritmos concordam, e a recomendação coincide com a consulta direta aos dados: Rock é o estilo de que mais gostam as pessoas que não gostam de Tabuleiro (86% delas). A Tabela 8 resume as recomendações.

Tabela 8 – Resumo das recomendações

Perfil	Algoritmo	Grupo usado	Recomendação
Gosta de Brega	K-Means	0 (Brega = 0,26)	Survival (0,92)
Gosta de Brega	Aglomerativo	0 (Brega = 0,28)	RPG (0,93)
Não gosta de Tabuleiro	K-Means	1 (Tabuleiro = 0,55)	Rock (0,91)
Não gosta de Tabuleiro	Aglomerativo	1 (Tabuleiro = 0,59)	Rock (0,97)

Fonte: elaborada pelo autor (2026).

5. Conclusão

O K-Means e o agrupamento aglomerativo com ligação de Ward, ambos com três grupos, produziram partições muito parecidas (87,5% de concordância; ARI de 0,657) e perfis com interpretação clara. As diferenças se concentram na fronteira entre os dois primeiros perfis, o que é coerente com os algoritmos: o K-Means otimiza uma partição global e revisável, enquanto o aglomerativo constrói os grupos por fusões locais e definitivas.

Os experimentos mostraram que a escolha dos parâmetros importa: as ligações single e average geraram partições degeneradas, e o K-Means com uma só inicialização é instável. Também mostraram que as métricas internas devem ser analisadas em conjunto com o tamanho e os centroides dos grupos. Por fim, as silhuetas baixas indicam que os gostos formam um contínuo, e os grupos devem ser vistos como perfis aproximados, adequados a recomendações gerais como as feitas neste trabalho.

6. Declaração de Uso de Inteligência Artificial

Durante a elaboração deste trabalho, foi utilizado o assistente de inteligência artificial Claude (modelo Claude Opus 5.5, da Anthropic), por meio da ferramenta Claude Code, para escrever o código em Python (scikit-learn, pandas e matplotlib) que executa os experimentos, armazena os grupos e centroides e gera as figuras; para executar o código e organizar os resultados; e para redigir a versão inicial deste texto e formatá-lo. A escolha das configurações, a interpretação dos grupos e as recomendações foram revisadas pelo autor, que se responsabiliza pelo conteúdo final. Nenhum dado externo foi usado para completar o conjunto de dados.

7. Referências

ARTHUR, D.; VASSILVITSKII, S. k-means++: the advantages of careful seeding. *In*: ANNUAL ACM-SIAM SYMPOSIUM ON DISCRETE ALGORITHMS, 18., 2007, New Orleans. **Proceedings** [...]. Philadelphia: SIAM, 2007. p. 1027-1035.

MACQUEEN, J. Some methods for classification and analysis of multivariate observations. *In*: BERKELEY SYMPOSIUM ON MATHEMATICAL STATISTICS AND PROBABILITY, 5., 1967, Berkeley. **Proceedings** [...]. Berkeley: University of California Press, 1967. v. 1, p. 281-297.

PEDREGOSA, F. *et al.* Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, [*s. l.*], v. 12, p. 2825-2830, 2011.

ROUSSEEUW, P. J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. **Journal of Computational and Applied Mathematics**, [*s. l.*], v. 20, p. 53-65, 1987.

WARD, J. H. Hierarchical grouping to optimize an objective function. **Journal of the American Statistical Association**, [*s. l.*], v. 58, n. 301, p. 236-244, 1963.